

MACHINE LEARNING

LESSON 1: Introduction

CARSTEN EIE FRIGAARD HENRIK DANIEL KJELDSEN





Undervisere

Carsten Eie Frigaard:

kursusholder,

rum: E311,

email: cef@ase.au.dk

Henrik Daniel Kjeldsen:

kursusholder,

rum: E301,

email: hdk@ase.au.dk

Peter Ahrendt hjælpelærer,

rum: E308,

email: pah@ase.au.dk







Litteratur

"Hands-On Machine Learning with Scikit-Learn and TensorFlow", Aurélien Géron, O'Reilly, 2017



- ► [HOML]→ udtales (Brian) Holm!
- ► [HOML] i ny version, forår 2019, som *ikke* bruges.
- Plus yderligere materiale (brug links i BB).
- NB: ITMAL helt nyt kursus; fejl og mangler påpeges!

Læringsmål

Når kurset er afsluttet forventes det at den studerende kan:

- Overordnet:
 - Gengive udvalgt machine learning historie og teori, og dettes betydning for praktisk anvendelse.
 - Diskutere litteratur om machine learning og vurdere materialets teoretiske og praktiske anvendelses muligheder.
- ML Data og algoritmer:
 - Beskrive betydningen af data kvalitet i machine learning, samt anvende udvalgte data-behandlingsteknikker.
 - Sammenligne og vurdere forskellige algoritmer og teknikkers anvendelighed i forbindelse med praktiske projekter.
- ITMAL i relation til praktiske projekter:
 - Anvende udvalgte kodebiblioteker (frameworks) og værktøjer til machine learning.
 - Anvende udvalgte machine learning teknikker i praktiske opgaver og projekter.
- Hardware:
 - Redegøre hardwares betydning for machine learning algoritmer.

Eksamen

Prøveform

Aflevering og godkendelse af alle journaler.

Bedømmelse

Godkendt/lkke godkendt, ingen censur.

Forudsætninger for prøvedeltagelse

For at kunne bestå kurset skal der i løbet af semesteret være afleveret et antal obligatoriske opgaver. Der vil være deadlines for afleveringen af de enkelte opgaver.

Bemærkninger

Beståelsen af kurset sker på baggrund af én samlet vurdering af de afleverede opgaver, hvor der vil blive lagt vægt på, om den studerende opfylder punkterne i kvalifikationsbeskrivelsen. Bedømmelsen foretages kun af eksaminator (underviser).

Reeksamen

Næste ordinære eksamen. Samme procedure som ved den ordinære eksamen.
 Der skal afleveres nye opgaver til eksaminationen.

Journalafleveringer: J1, J2 og J3

- J1: Q-Opgavesæt (jupyter notebooks).
- J2: Q-Opgavesæt (jupyter notebooks).
- J3: Mini-projekt:
 - For the final journal, you must design and implement a full machine learning system. You have relative free hands...

Criterions (extract):

- Data must be split in a training-test set...
- Your machine learning algorithm must be described in depth...
- The system must be evaluated via a suitable performance metric-..

NOTE₀: Afleveringsformat frit (PDF, .ipynb, etc.).

NOTE₁: J3 vil blive specificeret på BB, med projektforslag.

NOTE₂: J3 konflikt med BA projekter?

Syllabus

Preliminary...

- L01: Intro.
- L02: End-to-end demo.
- L03: Classification.
- LO4: Training.
- LO5: Regularization and Searching.
- LO6: Reverse engineering of Learning.
- L07: Breaking the curse of dimensionality.
- L08: Deep learning I.
- L09: Adverserial examples.
- L10: Deep learning II.
- L11: Frameworks and Hardware + J3 Project.
- L12: J3 Project (until L16).

ITMAL Nomenklatur

```
[HOML]: Hands-On Machine Learning bog, aka (B.)Holm.
```

```
[GITHOML]: Git repository for [HOML].
```

[GITMAL]: Git repository for ITMAL kursus opgaver, opdater for hver ny lektion!

[G]: ITMAL gruppe, med tre studerende, (evt. fire).

[SG]: ITMAL super-gruppe, ved nogle af opgaverne.

[J1]: Journal 1, osv. (J2/J3).

[L01]: Lektion 1, osv.

NOTE: se fuld liste på 'BB | General | Nomenclature'.

END Kursus intro/BEGIN ML intro





- Python is an interpreted high-level programming language for general-purpose programming. Created by Guido van Rossum and first released in 1991, Python has a design philosophy that emphasizes code readability, notably using significant whitespace. It provides constructs that enable clear programming on both small and large scales.
- Python features a dynamic type system and automatic memory management. It supports multiple programming paradigms, including object-oriented, imperative, functional and procedural, and has a large and comprehensive standard library.
- Python interpreters are available for many operating systems.





Anaconda and Jupyter Introduction ANACONDA Jupyter

- Anaconda: a python distribution [https://www.anaconda.com].
- Jupyter notebook: interactive python development environment (GUI IDE), distributed with the Anaconda package.
- Jupyter is an anagram of: Julia, Python, and R.
- Jupyter notebook method:
 - √ polyglot environment, mixing source code, markdown test and formulas (LaTeX),
 - √ interactive trial-and-error environment,
 - ÷ not good at source-code level debugging.
- ▶ Other IDE's:
 - Spyder (Anaconda),
 - VSCode (Microsoft),
 - and many others...

Scikit-learn Introduction

- Scikit-learn: a page/site for machine Learning in python.
- ▶ http://scikit-learn.org
- ▶ git@github.com:scikit-learn/scikit-learn.git



Classification

Identifying to which category an object belongs to.

Applications: Spam detection, Image recognition.

Algorithms: SVM, nearest neighbors,

Regression

Predicting a continuous-valued attribute associated with an object.

Applications: Drug response, Stock prices.

Algorithms: SVR, ridge regression,
Lasso, ... — Examples

Clustering

Automatic grouping of similar objects into sets.

Applications: Customer segmentation, Grouping experiment outcomes

Algorithms: k-Means, spectral clustering, mean-shift, ... — Examples

Vores videnskabelige framework

Sat sammen...









Gode hjælpe og dokumentations-systemer..

Alternativer kunne være...

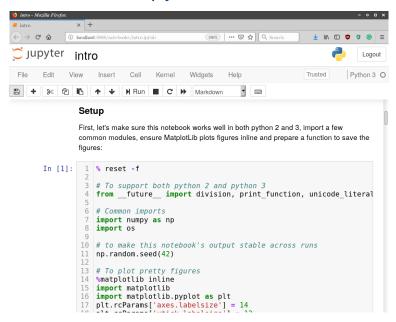








Anaconda and Jupyter Demo



Anaconda and Jupyter Demo: Highlights...

- Polyglot miljø:
 - lidt ala Matlab IDE,
 - markdown (HTML+LaTeX)-og-Python-i-een = polyglot,
 - alt kører i browser, lokalt eller på server.
- Quickstart:
 - åbn via http://localhost:8888 (efter launch),
 - ENTER på celle: editer celle,
 - CTRL+ENTER: kør celle,
 - SHIFT+TAB: hjælp på funktion,
 - TAB: tab-completion.
- Magics:
 - ▶ nulstil vars: % reset -f,
 - ▶ inline plots: % matplotlib inline.
- ► Hints
 - Pas på globale vars (igen scopes ml. .ipynb celler),
 - Brug menu 'Help' og find shortcuts i 'open command palette'n,
 - Hvis du er C++ haj: alt er anderledes!

Machine learning taksonomi

- Læringstyper:
 - supervised (mest om dette i ITMAL),
 - unsupervised.
 - [semisupervised], [reinforced learning].
- Output klasser:
 - classification (ham/spam),
 - regression (h(x) = y),
- Læring via data:
 - batch læring (al data),
 - [inkrementel læring (on-the-fly)].
- Prediktions/generaliserings model:
- model-based (pattern-detection, byg intern model),
 - [instance-based (lær al data udenad)],
- Typiske ML fejl klasser:
- ► for lidt trænings data (small-data, brug cross-validation),
 - sampling noise, sampling bias (ved manglende statificering),
 - outliers og dårlig data (i big-data),
 model og algoritme fejl: underfitting/overfitting.

Machine learning terminologi

- X, x: input data matrix og vektor,
- **y**, y: output data vektor og skalar,
 - θ : model parametre,
 - h: hypothesis funktion; typer af ML algos:

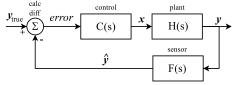
Bayes classifier, k-Nearest Neighbors, Linear Reg., Logistic Reg., SVM, Decision Trees, Random Forest, Neural Networks, k-Means, ...

- y_{true}: ground truth, til supervised learning,
- y_{pred} : predikteret værdi, aka \hat{y} ,
- attribut: data type, f.eks. salgspris, dog anvendes 'feature' typisk i stedet for attribut!
- feature: data attribut plus value, f.eks. $\lambda_{\text{salgspris}} = \42 ,
- loss fun.: loss/cost/error/objective funktion, som minimeres i fitting, jo lavere jo bedre et fit,
- score fun.: score/fitness/goodness funktion, jo højere jo bedre, bruges typisk efter fit-minimeringingen
 - til model inspektion og eftervalidering.

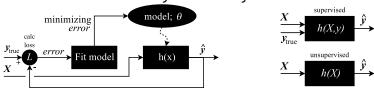
Supervised learning, blok diagram

Fra white-box til black-box

Almindelig white-box negativt feedback control block diagram, som for lineære og tids-uafhængige funktioner kan Laplace analyseres 'i det uendelige':



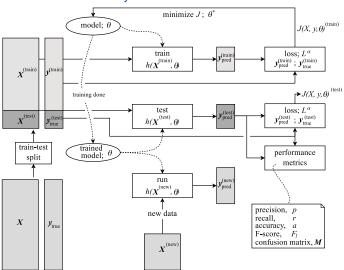
Supervised machine learning block diagram:



Valg af: Loss funktion, model/hypothesis funktion, that's is! (excl. hyperparametre). Alt er nu black-box.

Supervised learning, blok diagram

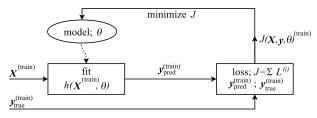
Sneak-preview af 'the full monty'...



NOTE: Kun et pre-view; vi går igennem detaljerne i figuren i de mange følgende lektioner.

Q-Øvelse

ML supervised learning data flow model: Training (fit).



X^(train) : trænings matrix input data,

 $\mathbf{x}^{(\text{train})}$: data input vector; $\mathbf{x} = [x_1, x_2, \cdots, x_d]$,

 $\mathbf{y}_{\text{true}}^{(\text{train})}$: trænings input ground truth vektor,

 $\mathbf{y}_{\text{pred}}^{(\text{train})}$: predikteret værdi for y, aka \hat{y}

 θ : model parametre,

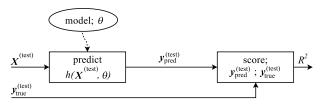
h : hypothesis funktion, aka. ML algoritmen,

 $L^{(i)}$: loss funktion (individuel), $L^{(i)}(y_{\text{pred}}^{(i)}, y_{\text{true}}^{(i)})$

J: loss funktion (summeret), $J = \frac{1}{n} \sum_{i} L^{(i)}$. med **x** havende dimensionalitet d... mere om denne og loss funktioner i LO2.

Q-Øvelse

ML supervised learning data flow model: Prediction



Øvelse:

- træn en lineær regressions model, (Scikit-learn fit-predict interface),
- gå i detaljen med R² score funktionen,
 (NOTE: test data er lig train data for denne øvelse),
- check k-Nearest Neighbors modelen ud på data, sammenlign kNN-score med lineær regression-score.